Veille & Amélioration Segmentation sémantique Cityscapes

Preuve de concept — 7 architectures, 27 runs

Cityscapes — le dataset

2 975	500	1 525
Images train	Images val	Images test

Images 2048×1024 — 50 villes européennes — 32 catégories regroupées en 8 classes

Déséquilibre : flat/construction > 70% des pixels — object ~2% — human ~0.4%

Les 8 classes

- void
- flat
- construction
- object
- nature
- sky
- human
- vehicle

Choix des modèles

ConvNeXt Tiny

CNN modernisé — CVPR 2022

SegFormer MiT-B0 / B5

Transformer dédié — NeurIPS 2021

EoMT / DINOv2-Base

Foundation model auto-supervisé — arXiv 2024

Sources

ConvNeXt — A ConvNet for the 2020s (CVPR 2022)

arxiv.org/abs/2201.03545 • tf.keras.applications.ConvNeXtTiny

SegFormer — Simple and Efficient Design (NeurIPS 2021)

arxiv.org/abs/2105.15203 • keras.io/api/keras_hub/models/seg_former

EoMT — You Only Need One Thing At A Time (arXiv 2024)

github.com/tue-mps/eomt • huggingface.co/tue-mps

DINOv2 — Learning Robust Visual Features without Supervision (Meta AI, 2023)

huggingface.co/facebook/dinov2-base • github.com/facebookresearch/dinov2

Autres ressources

cityscapes-dataset.com • albumentations.ai • machinelearningmastery.com

Du CNN classique au foundation model

CNN classique	U-Net + VGG16 / ResNet50	Baseline
CNN modernisé	U-Net + ConvNeXt Tiny	CVPR 2022
Transformer pur	SegFormer MiT-B0 / B5	NeurIPS 2021
Foundation model	EoMT / DINOv2 (auto-supervisé)	arXiv 2024

Protocole d’entraînement

Paramètre	Valeur
Phase 1	Encodeur gelé, tête seule — 50 ep max, LR 1e-3
Phase 2	Fine-tuning complet — 30 ep max, LR 1e-4
Loss	CE + 0.5 × Dice (IGNORE=255 exclu)
Métrique	val_mIoU (validation, sans augmentation)
Augmentation	Albumentations : flip, rotation, luminosité, bruit, flou
Batch / GPU	Batch 4, seed 42, GTX 1080 Ti (11 Go VRAM)

Paramètres explorés — 27 runs

Paramètre	Valeurs	Impact
Résolution	128, 256, 512, 1024	**+3 à +6 pts (256→512)**
Augmentation	avec vs sans	**+10 pts**
Loss	CE seule vs CE+Dice	**+10 à +12 pts**
Mode	scratch / frozen / finetune	variable
Modèles	7 architectures	**ConvNeXt > tous**

Baselines — 256×256

Projet précédent : pipeline complet (entraînement + API FastAPI + app Streamlit + déploiement Replit)

Modèle	Val mIoU	Mode	Époques
U-Net Scratch	**0.7539**	scratch	40
U-Net + ResNet50 FT	**0.7471**	finetune	30
U-Net + VGG16 FT	**0.7465**	finetune	30
ResNet50 Frozen	0.7440	frozen	40
VGG16 Frozen	0.7170	frozen	40

Nouveaux modèles — 256×256

Modèle	Val mIoU	Durée	Type
ConvNeXt Tiny FT	**0.7738**	—	CNN+
EoMT MultiScale + Cosine	**0.7338**	168 min	ViT
SegFormer MiT-B5	**0.7213**	148 min	Transf.
SegFormer MiT-B0 (50+30)	0.7140	273 min	Transf.
EoMT DINOv2 (tête dense)	0.7119	~280 min	ViT

Résolution 256 vs 512

Modèle	Val 256	Val 512	Gain
ConvNeXt Tiny FT	0.7738	**0.8256**	**+5.2 pts**
VGG16 FT	0.7465	**0.7970**	+5.1 pts
SegFormer B0 Frozen	~0.71	**0.7805**	+6.7 pts
ResNet50 Frozen	0.7440	**0.7754**	+3.1 pts

0.8256

Meilleur run global

N°1

ConvNeXt FT — 512×512

MiT-B5 vs MiT-B0

0.7140

MiT-B0 (~3.8M params)

0.7213

MiT-B5 (~82M params)

273 min

B0 — durée

148 min

B5 — durée

Plus gros = plus rapide. Le facteur limitant c’est la résolution, pas le modèle.

Les classes en difficulté

Classe	IoU typique	% pixels	Problème
flat / sky / vehicle	**> 0.85**	~60%	—
object	**0.30 – 0.39**	~2%	Petit, confusion avec construction
human	**0.57 – 0.63**	~0.4%	Petit, confusion avec vehicle

Pistes : class weights, Focal Loss, résolution 512+

Limites & améliorations

Limites

- Résolution 256 pénalise object/human et le score global
- Pas de class weights
- Pas de TTA à l’inférence
- GPU 1080 Ti : pas de mixed precision
- EoMT simplifié (sans mask queries)

Améliorations

- Class weights / Focal Loss
- Entraînement complet 512, 1024 (50+30 ep)
- MiT-B5 à 512×512 où supérieur
- TTA (flips + multi-scale)
- Post-processing CRF
- EoMT complet avec mask queries, modèles plus lourd, plus de paramètres … etc

Le dashboard

EDA	Exemples d’images, comptages, transformations
Comparaison	Tableau filtrable des 27 runs, graphiques Plotly, courbes
À propos	Méthodo, modèles, palette, critères WCAG

Déploiement

Élément	Détail
Cloud	Replit (intégration GitHub)
Cache EDA	precompute_eda.py → eda_cache/ (stats.json + 30 images)
Modèles	Stockés sur HuggingFace, téléchargés au démarrage
CI/CD	GitHub Actions : flake8 + 12 tests pytest

Démo live

Merci !